

Back-Propagation-Neural-Network

language C++

last commit today

本项目是基于C++实现基础BP神经网络，有助于深入理解BP神经网络原理。

是对项目[GavinTechStudio/bpnn_with_cpp](https://github.com/GavinTechStudio/bpnn_with_cpp)的代码重构。

项目结构

```
1  .
2  ├── CMakeLists.txt
3  ├── README.md
4  ├── data
5  |   ├── testdata.txt
6  |   └── traindata.txt
7  ├── docs
8  |   └── formula.md
9  ├── img
10 |   └── net-info.png
11 ├── lib
12 |   ├── Config.h
13 |   ├── Net.cpp
14 |   ├── Net.h
15 |   ├── Utils.cpp
16 |   └── Utils.h
17 └── main.cpp
18
19 4 directories, 12 files
```

主要文件

- Net: 网络具体实现
- Config: 网络参数设置
- Utils: 工具类
 - 数据加载
 - 激活函数
- main: 网络具体应用

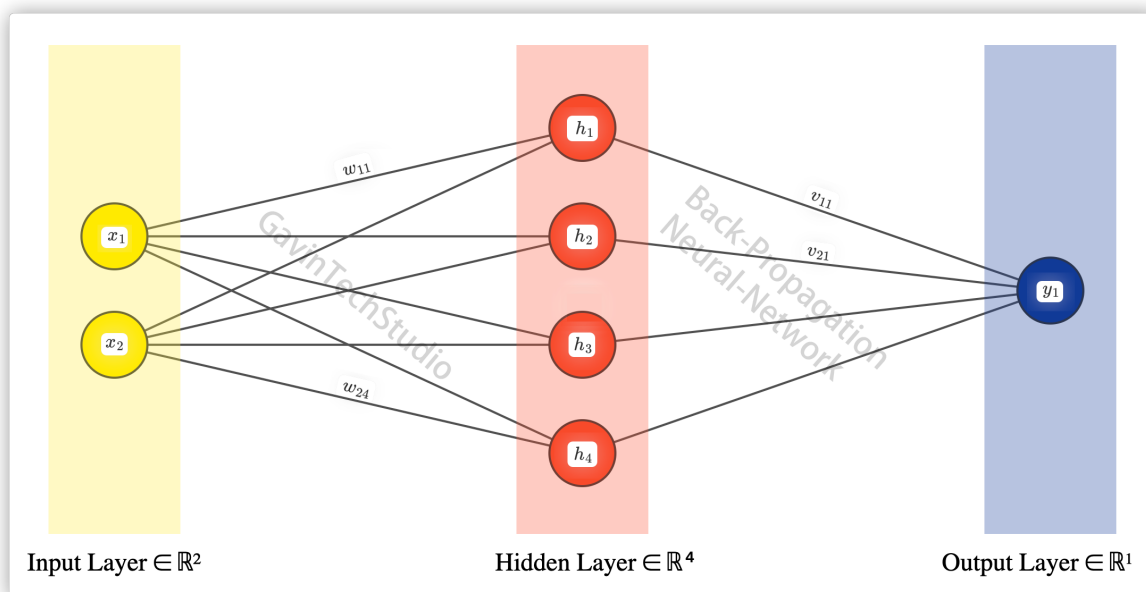
训练原理

具体公式推导请看视频讲解[彻底搞懂BP神经网络 理论推导+代码实现 \(C++\)](https://www.bilibili.com/video/BV18t4y1g7yY/) 哔哩哔哩bilibili

本部分文档包含大量数学公式，由于GitHub的README页面不支持数学公式渲染，推荐以下阅读方式：

1. 如果您使用的是Chrome、Edge、Firefox等浏览器，可以安装插件[MathJax Plugin for Github](https://chrome.google.com/webstore/detail/mathjax-plugin-for-github/blhifnejkegddkajcdfkfdmclcgfnakfao)（需要访问chrome web store）。
2. 使用[PDF](#)的方式进行阅读。
3. 使用[预渲染的静态网页](#)进行阅读（推荐）。

0. 神经网络结构图



1. Forward（前向传播）

1.1 输入层向隐藏层传播

$$h_j = \sigma\left(\sum_i x_i w_{ij} - \beta_j\right)$$

其中 h_j 为第 j 个隐藏层节点的值， x_i 为第 i 个输入层节点的值， w_{ij} 为第 i 个输入层节点到第 j 个隐藏层节点的权重， β_j 为第 j 个隐藏层节点偏置值， $\sigma(x)$ 为**Sigmoid**激活函数，后续也将继续用这个表达，其表达式如下

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

本项目中的代码实现如下：

```
1  for (size_t j = 0; j < Config::HIDENODE; ++j) {
2      double sum = 0;
3      for (size_t i = 0; i < Config::INNOD; ++i) {
4          sum += inputLayer[i]->value *
5              inputLayer[i]->weight[j];
6      }
7      sum -= hideLayer[j]->bias;
8
9      hideLayer[j]->value = Utils::sigmoid(sum);
10 }
```

1.2 隐藏层向输出层传播

$$\hat{y}_k = \sigma\left(\sum_j h_j v_{jk} - \lambda_k\right)$$

其中 \hat{y}_k 为第 k 个输出层节点的值（预测值）， h_j 为第 j 个隐藏层节点的值， v_{jk} 为第 j 个隐藏层节点到第 k 个输出层节点的权重， λ_k 为第 k 个输出层节点的偏置值， $\sigma(x)$ 为激活函数。

本项目中的代码实现如下：

```

1  for (size_t k = 0; k < Config::OUTNODE; ++k) {
2      double sum = 0;
3      for (size_t j = 0; j < Config::HIDENODE; ++j) {
4          sum += hideLayer[j]->value *
5              hideLayer[j]->weight[k];
6      }
7      sum -= outputLayer[k]->bias;
8
9      outputLayer[k]->value = Utils::sigmoid(sum);
10 }

```

2. 计算损失函数 (Loss Function)

损失函数定义如下：

$$Loss = \frac{1}{2} \sum_k (y_k - \hat{y}_k)^2$$

其中 y_k 为第 k 个输出层节点的目标值（真实值）， \hat{y}_k 为第 k 个输出层节点的值（预测值）。

本项目中的代码实现如下：

```

1  double loss = 0.f;
2
3  for (size_t k = 0; k < Config::OUTNODE; ++k) {
4      double tmp = std::fabs(outputLayer[k]->value - out[k]);
5      los += tmp * tmp / 2;
6  }

```

3. Backward (反向传播)

利用梯度下降法进行优化。

3.1 计算 $\Delta\lambda_k$ (输出层节点偏置值的修正值)

其计算公式如下（激活函数为Sigmoid时）：

$$\Delta\lambda_k = -\eta(y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)$$

其中 η 为学习率（其余变量上方已出现过不再进行标注）。

本项目中的代码实现如下：

```

1  for (size_t k = 0; k < Config::OUTNODE; ++k) {
2      double bias_delta =
3          -(out[k] - outputLayer[k]->value) *
4          outputLayer[k]->value *
5          (1.0 - outputLayer[k]->value);
6
7      outputLayer[k]->bias_delta += bias_delta;
8  }

```

3.2 计算 Δv_{jk} (隐藏层节点到输出层节点权重的修正值)

其计算公式如下 (激活函数为Sigmoid时) :

$$\Delta v_{jk} = \eta(y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)h_j$$

其中 h_j 为第 j 个隐藏层节点的值 (其余变量上方已出现过不再进行标注)。

本项目中的代码实现如下:

```
1  for (size_t j = 0; j < Config::HIDENODE; ++j) {
2      for (size_t k = 0; k < Config::OUTNODE; ++k) {
3          double weight_delta =
4              (out[k] - outputLayer[k]->value) *
5              outputLayer[k]->value *
6              (1.0 - outputLayer[k]->value) *
7              hideLayer[j]->value;
8
9          hideLayer[j]->weight_delta[k] += weight_delta;
10     }
11 }
```

3.3 计算 $\Delta \beta_j$ (隐藏层节点偏置值的修正值)

其计算公式如下 (激活函数为Sigmoid时) :

$$\Delta \beta_j = -\eta \sum_k (y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)v_{jk}h_j(1 - h_j)$$

其中 v_{jk} 为第 j 个隐藏层节点到第 k 个输出层节点的权重 (其余变量上方已出现过不再进行标注)。

本项目中的代码实现如下:

```
1  for (size_t j = 0; j < Config::HIDENODE; ++j) {
2      double bias_delta = 0.f;
3      for (size_t k = 0; k < Config::OUTNODE; ++k) {
4          bias_delta +=
5              -(out[k] - outputLayer[k]->value) *
6              outputLayer[k]->value *
7              (1.0 - outputLayer[k]->value) *
8              hideLayer[j]->weight[k];
9      }
10     bias_delta *=
11         hideLayer[j]->value *
12         (1.0 - hideLayer[j]->value);
13
14     hideLayer[j]->bias_delta += bias_delta;
15 }
```

3.4 计算 Δw_{ij} (输入层节点到隐藏层节点权重的修正值)

其计算公式如下 (激活函数为Sigmoid时) :

$$\Delta w_{ij} = \eta \sum_k (y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)v_{jk}h_j(1 - h_j)x_i$$

其中 x_i 为第 i 个输入层节点的值 (其余变量上方已出现过不再进行标注)。

本项目中的代码实现如下:

```
1  for (size_t i = 0; i < Config::INNOD; ++i) {
2      for (size_t j = 0; j < Config::HIDENODE; ++j) {
3          double weight_delta = 0.f;
4          for (size_t k = 0; k < Config::OUTNODE; ++k) {
5              weight_delta +=
6                  (out[k] - outputLayer[k]->value) *
7                  outputLayer[k]->value *
8                  (1.0 - outputLayer[k]->value) *
9                  hideLayer[j]->weight[k];
10         }
11         weight_delta *=
12             hideLayer[j]->value *
13             (1.0 - hideLayer[j]->value) *
14             inputLayer[i]->value;
15
16         inputLayer[i]->weight_delta[j] += weight_delta;
17     }
18 }
```