

Back-Propagation-Neural-Network



本项目是对项目 [GavinTechStudio/bpnn with cpp](#) 的代码重构，基于C++实现基础BP神经网络，有助于深入理解BP神经网络原理。

项目结构

```
.
├── CMakeLists.txt
├── data
│   ├── testdata.txt
│   └── traindata.txt
├── lib
│   ├── Config.h
│   ├── Net.cpp
│   ├── Net.h
│   ├── Utils.cpp
│   └── Utils.h
└── main.cpp
```

主要框架

- Net: 网络具体实现
- Config: 网络参数设置
- Utils: 工具类
 - 数据加载
 - 激活函数
- main: 网络具体应用

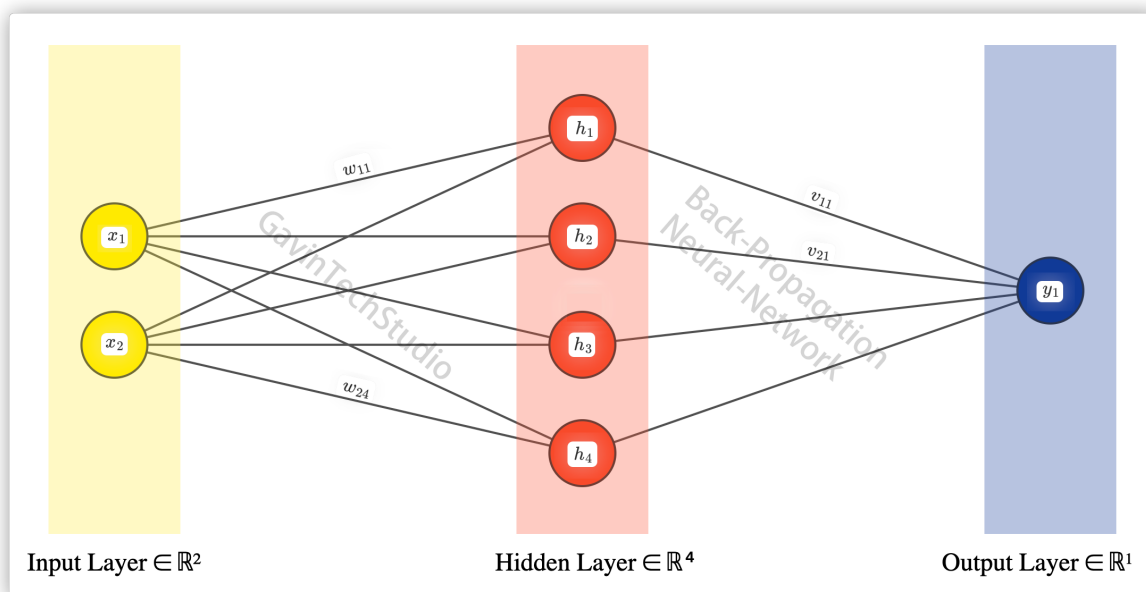
训练原理

具体公式推导请看视频讲解[彻底搞懂BP神经网络 理论推导+代码实现 \(C++\)](#)

注意：本部分文档包含大量数学公式，由于GitHub markdown不支持数学公式渲染，推荐以下阅读方式：

1. 如果您使用的是Chrome、Edge、Firefox等浏览器，可以安装插件[MathJax Plugin for Github](#)（需要网络能够访问chrome web store）。
2. 使用[PDF](#)的方式进行阅读（**推荐**）。
3. 使用[预渲染的静态网页](#)进行阅读（**推荐**）。
4. 按 `.` 键或[点击链接](#)进入GitHub在线IDE预览 README.md 文件。

0. 神经网络结构图



1. Forward（前向传播）

1.1 输入层向隐藏层传播

$$h_j = \sigma\left(\sum_i x_i w_{ij} - \beta_j\right)$$

其中 h_j 为第 j 个隐藏层节点的值， x_i 为第 i 个输入层节点的值， w_{ij} 为第 i 个输入层节点到第 j 个隐藏层节点的权重， β_j 为第 j 个隐藏层节点偏置值， $\sigma(x)$ 为**Sigmoid**激活函数，后续也将继续用这个表达，其表达式如下

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

本项目中的代码实现如下：

```
for (size_t j = 0; j < Config::HIDENODE; ++j) {
    double sum = 0;
    for (size_t i = 0; i < Config::INNODE; ++i) {
        sum += inputLayer[i]->value *
            inputLayer[i]->weight[j];
    }
    sum -= hiddenLayer[j]->bias;

    hiddenLayer[j]->value = Utils::sigmoid(sum);
}
```

1.2 隐藏层向输出层传播

$$\hat{y}_k = \sigma\left(\sum_j h_j v_{jk} - \lambda_k\right)$$

其中 \hat{y}_k 为第 k 个输出层节点的值（预测值）， h_j 为第 j 个隐藏层节点的值， v_{jk} 为第 j 个隐藏层节点到第 k 个输出层节点的权重， λ_k 为第 k 个输出层节点的偏置值， $\sigma(x)$ 为激活函数。

本项目中的代码实现如下：

```

for (size_t k = 0; k < Config::OUTNODE; ++k) {
    double sum = 0;
    for (size_t j = 0; j < Config::HIDENODE; ++j) {
        sum += hiddenLayer[j]->value *
            hiddenLayer[j]->weight[k];
    }
    sum -= outputLayer[k]->bias;

    outputLayer[k]->value = Utils::sigmoid(sum);
}

```

2. 计算损失函数 (Loss Function)

损失函数定义如下：

$$Loss = \frac{1}{2} \sum_k (y_k - \hat{y}_k)^2$$

其中 y_k 为第 k 个输出层节点的目标值（真实值）， \hat{y}_k 为第 k 个输出层节点的值（预测值）。

本项目中的代码实现如下：

```

double loss = 0.f;

for (size_t k = 0; k < Config::OUTNODE; ++k) {
    double tmp = std::fabs(outputLayer[k]->value - label[k]);
    los += tmp * tmp / 2;
}

```

3. Backward (反向传播)

利用梯度下降法进行优化。

3.1 计算 $\Delta\lambda_k$ (输出层节点偏置值的修正值)

其计算公式如下（激活函数为Sigmoid时）：

$$\Delta\lambda_k = -\eta(y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)$$

其中 η 为学习率（其余变量上方已出现过不再进行标注）。

本项目中的代码实现如下：

```

for (size_t k = 0; k < Config::OUTNODE; ++k) {
    double bias_delta =
        -(label[k] - outputLayer[k]->value) *
        outputLayer[k]->value *
        (1.0 - outputLayer[k]->value);

    outputLayer[k]->bias_delta += bias_delta;
}

```

3.2 计算 Δv_{jk} （隐藏层节点到输出层节点权重的修正值）

其计算公式如下（激活函数为Sigmoid时）：

$$\Delta v_{jk} = \eta(y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)h_j$$

其中 h_j 为第 j 个隐藏层节点的值（其余变量上方已出现过不再进行标注）。

本项目中的代码实现如下：

```
for (size_t j = 0; j < Config::HIDENODE; ++j) {
    for (size_t k = 0; k < Config::OUTNODE; ++k) {
        double weight_delta =
            (label[k] - outputLayer[k]->value) *
            outputLayer[k]->value *
            (1.0 - outputLayer[k]->value) *
            hiddenLayer[j]->value;

        hiddenLayer[j]->weight_delta[k] += weight_delta;
    }
}
```

3.3 计算 $\Delta\beta_j$ （隐藏层节点偏置值的修正值）

其计算公式如下（激活函数为Sigmoid时）：

$$\Delta\beta_j = -\eta \sum_k (y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)v_{jk}h_j(1 - h_j)$$

其中 v_{jk} 为第 j 个隐藏层节点到第 k 个输出层节点的权重（其余变量上方已出现过不再进行标注）。

本项目中的代码实现如下：

```
for (size_t j = 0; j < Config::HIDENODE; ++j) {
    double bias_delta = 0.f;
    for (size_t k = 0; k < Config::OUTNODE; ++k) {
        bias_delta +=
            -(label[k] - outputLayer[k]->value) *
            outputLayer[k]->value *
            (1.0 - outputLayer[k]->value) *
            hiddenLayer[j]->weight[k];
    }
    bias_delta *=
        hiddenLayer[j]->value *
        (1.0 - hiddenLayer[j]->value);

    hiddenLayer[j]->bias_delta += bias_delta;
}
```

3.4 计算 Δw_{ij} （输入层节点到隐藏层节点权重的修正值）

其计算公式如下（激活函数为Sigmoid时）：

$$\Delta w_{ij} = \eta \sum_k (y_k - \hat{y}_k)\hat{y}_k(1 - \hat{y}_k)v_{jk}h_j(1 - h_j)x_i$$

其中 x_i 为第 i 个输入层节点的值（其余变量上方已出现过不再进行标注）。

本项目中的代码实现如下：

```

for (size_t i = 0; i < Config::INNOD; ++i) {
    for (size_t j = 0; j < Config::HIDENODE; ++j) {
        double weight_delta = 0.f;
        for (size_t k = 0; k < Config::OUTNODE; ++k) {
            weight_delta +=
                (label[k] - outputLayer[k]->value) *
                outputLayer[k]->value *
                (1.0 - outputLayer[k]->value) *
                hiddenLayer[j]->weight[k];
        }
        weight_delta *=
            hiddenLayer[j]->value *
            (1.0 - hiddenLayer[j]->value) *
            inputLayer[i]->value;

        inputLayer[i]->weight_delta[j] += weight_delta;
    }
}

```